

(19)中华人民共和国国家知识产权局



(12)发明专利申请

(10)申请公布号 CN 111161152 A

(43)申请公布日 2020.05.15

(21)申请号 201911408041.3

(22)申请日 2019.12.31

(71)申请人 西安电子科技大学

地址 710071 陕西省西安市太白南路2号

(72)发明人 魏德运 王昭武 李远敏 江明杰
慎毅

(74)专利代理机构 陕西电子工业专利中心
61205

代理人 王品华

(51)Int.Cl.

G06T 3/40(2006.01)

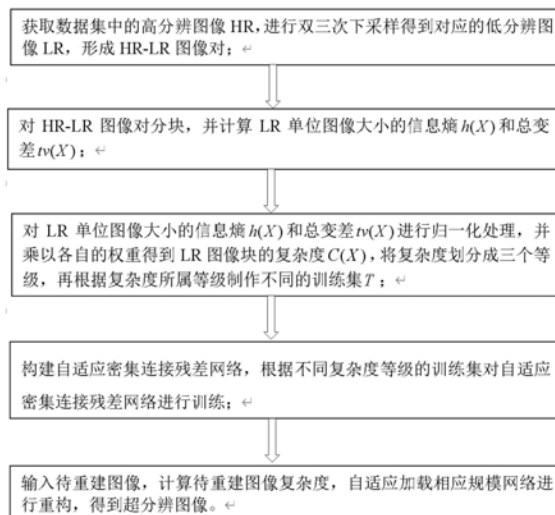
权利要求书5页 说明书10页 附图3页

(54)发明名称

基于自适应卷积神经网络的图像超分辨率方法

(57)摘要

本发明公开了一种基于自适应卷积神经网络的图像超分辨率方法,主要解决现有神经网络模型参数多、重构高分辨率图像时间开销大的问题。其实现方案是:获取训练数据,制作相应的训练集;构建由浅层特征提取、深层特征提取、特征融合和上采样四部分组成的自适应密集连接残差网络,其中深层特征部分包括简单图网络分支、一般图网络分支和复杂图网络分支;利用相应训练集对自适应密集连接残差网络进行训练,并计算待重建图像的复杂度;将不同复杂度的待重建图像输入到训练好的自适应密集连接残差网络,并选择对应的网络分支,输出超分辨率后的图像。本发明表达能力强,在较少的模型参数和时间开销下提高了重建性能,可用于医疗诊断,卫星成像及道路监控。



CN 111161152 A

1. 一种基于自适应卷积神经网络的图像超分辨率方法,其特征在于,包括如下:

(1) 对标准数据集中的高分辨率图像HR进行下采样,得到对应的低分辨率图像LR,形成HR-LR图像对;

(2) 将HR-LR图像对按指定大小进行分块,对每个LR图像块计算其单位图像大小的信息熵 $h(X)$ 和总变差 $tv(X)$;

(3) 将复杂度划分成三个等级,依次对应简单图,一般图和复杂图,对LR单位图像大小的信息熵和总变差进行归一化处理,并乘以各自权重,得到LR图像块复杂度 $C(X)$,再根据复杂度所属等级制作相应训练集 $T_i^{scale} = \{t_1^{scale}, t_2^{scale}, \dots, t_j^{scale}, \dots, t_N^{scale}\}$, T_i^{scale} 为第 i 个等级,放大因子为 $scale$ 的训练集, $i=1,2,3, scale=2,3,4, t_j^{scale}$ 为该训练集中第 j 个放大因子为 $scale$ 的HR-LR图像对, $j=1,2, \dots, N, N$ 为该训练集的样本总数;

(4) 构建依次由浅层特征提取、深层特征提取、特征融合和上采样四部分级联,并在全局进行残差学习的自适应密集连接残差网络,其中,深层特征提取部分根据输入图像复杂度的不同包含不同数量的特征消融块,形成不同网络分支;

(5) 以设定的概率确定选择哪种等级的训练集 T ,从所选数据集 T 中随机获取 $batch_size$ 个训练数据,并对这些数据随机做水平、垂直翻转和90度旋转操作处理,其中选择简单图像训练集的概率为0.1,选择一般图像训练集的概率为0.3,选择复杂图像训练集的概率为0.6;

(6) 将(5)处理后的数据输入到(4)构建的自适应密集连接残差网络中,并根据处理后数据的复杂度等级选择对应的网络进行训练,得到训练好的自适应密集连接残差网络;

(7) 按(2)和(3)对待重建图像按指定大小分块,计算每个块的复杂度 $C_i(X), i=1,2, \dots, M, M$ 为待重建图像所分成的总块数,计算所有块复杂度的平均值,并加上设定的阈值0.25,得到待重建图像的复杂度 $C(X)$;

(8) 将待重建图像输入到训练好的自适应密集连接残差网络,根据待重建图像复杂度 $C(X)$ 自适应选择对应的网络进行重构,得到超分辨率后的图像。

2. 根据权利要求1所述的方法,其特征在于:(1)中对标准数据集中的高分辨率图像HR进行下采样,是选用DIV2K的训练集,分别按照2倍、3倍、4倍尺寸进行双三次下采样处理,得到自适应密集连接残差网络的训练样本HR-LR图像。

3. 根据权利要求1所述的方法,其特征在于:

所述(2)中的指定大小,是指LR图像的大小为 32×32 ,HR图像的大小为 $(32 \times scale) \times (32 \times scale)$, $scale=2,3,4$ 分别对应2倍放大因子、3倍放大因子和4倍放大因子;

所述(2)中计算每个LR单位图像的信息熵 $h(X)$ 和总变差 $tv(X)$,其实现如下:

(2a) 将RGB通道的LR图像块转换成YCbCr通道的LR图像块,得到Y通道图像,其中转换公式如下:

$$Y = 0.299 \times R + 0.587 \times G + 0.114 \times B,$$

其中 R 代表红色通道, G 代表绿色通道, B 代表蓝色通道, Y 代表明亮度;

(2b) 计算Y通道图像的信息熵 $H(X)$:

$$H(X) = -\sum p(i) \log(p(i)), i=0,1, \dots, 255,$$

其中, $p(i)$ 表示图像块中灰度值 i 出现的概率;

(2c) 根据信息熵 $H(X)$ 计算Y通道图像单位图像信息熵 $h(X)$ ：

$$h(X) = \frac{H(X)}{32^2},$$

(2d) 计算Y通道图像的总变差 $TV(X)$ ：

$$TV(X) = \sum_{i,j} ((x_{i,j+1} - x_{i,j})^2 + (x_{i+1,j} - x_{i,j})^2)^{\frac{1}{2}},$$

其中 $x_{i,j}$ 为 (i,j) 位置处的灰度值, $x_{i,j+1}$ 为 $(i,j+1)$ 位置处的灰度值, $x_{i+1,j}$ 为 $(i+1,j)$ 处的灰度值；

(2e) 根据总变差 $TV(X)$ 计算Y通道图像单位图像总变差 $tv(X)$ ：

$$tv(X) = \frac{TV(X)}{32^2}。$$

4. 根据权利要求1所述的方法,其特征在于：

所述(3)中得到的LR图像块复杂度 $C(X)$,其实现过程如下：

(3a) 从(2)计算的LR单位图像信息熵 $h(X)$ 和总变差 $tv(X)$ 中分别找到最大值和最小值 $h_{\max}(X)$, $h_{\min}(X)$, $tv_{\max}(X)$, $tv_{\min}(X)$,其中 $h_{\max}(X)$, $tv_{\max}(X)$ 分别为最大单位图像信息熵和总变差, $h_{\min}(X)$, $tv_{\min}(X)$ 分别为最小单位图像信息熵和总变差；

(3b) 分别设置归一化后信息熵和总变差的权重为0.5；

(3c) 根据 $h_{\max}(X)$, $h_{\min}(X)$, $tv_{\max}(X)$, $tv_{\min}(X)$ 和设置的权重计算LR图像块复杂度：

$C(X) = 0.5 \times \frac{tv(X) - tv_{\min}(X)}{tv_{\max}(X) - tv_{\min}(X)} + 0.5 \times \frac{h(X) - h_{\min}(X)}{h_{\max}(X) - h_{\min}(X)}$,其中, $h(X)$, $tv(X)$ 分别为当前LR单位图像信息熵和总变差,且 $C(X) \in [0,1]$ ；

所述(3)中将复杂度划分成三个等级,是指将复杂度 $C(X) \in [0,1]$ 分为 $[0,0.4)$, $[0.4,0.6)$, $[0.6,1]$ 三个区间,分别对应简单图、一般图和复杂图三个等级。

5. 根据权利要求1所述的方法,其特征在于:(4)中自适应密集连接残差网络中的浅层特征部分,由两层卷积层级联构成,其公式表示如下：

$$F_{-1} = F_{s_1}(x),$$

$$F_0 = F_{s_2}(F_{-1})$$

其中, F_{-1} 为经过浅层特征部分的第一层卷积层输出, $F_{s_1}(\cdot)$ 为第一层浅层特征提取操作,卷积核大小为 3×3 ,输入图像维度为 $\dim=3$,输出特征维度为64, x 为输入图像；

F_0 为经过浅层特征部分的第二层卷积输出, $F_{s_2}(\cdot)$ 为第二层浅层特征提取操作,卷积核大小为 3×3 ,输入和输出特征维度均为64, F_{-1} 为浅层特征部分的第二层卷积输入。

6. 根据权利要求1所述的方法,其特征在于:(4)中自适应密集连接残差网络中的深层特征部分,由简单图网络分支、一般图网络分支和复杂图网络分支并联构成,每一网络分支又由不同数量的特征消融块密集连接组成,其中：

简单图网络分支包含2个特征消融块,一般图网络分支包含3个特征消融块,复杂图网络分支包含4个特征消融块。

7. 根据权利要求6所述的方法,其特征在于:所述三种网络分支之间的参数共享,即一般图网络分支的3个特征消融块中前2个特征消融块与简单图网络分支中2个特征消融块相同,复杂图网络分支的4个特征消融块中前3个特征消融块与一般图网络分支中的3个特征

消融块相同；

每个特征消融块的表达式如下：

$$F_1 = F_{11}(F_0),$$

$$F_2 = F_{12}(F_0, F_1),$$

$$F_3 = F_{13}(F_0, F_1, F_2),$$

$$F_4 = F_{14}(F_0, F_1, F_2, F_3)$$

其中, F_1 为经过第一个特征消融块的输出, 第一个特征消融块包含一层卷积层, 卷积核大小为 3×3 , 输入和输出特征维度为 64, $F_{11}(\cdot)$ 为第一个特征消融块操作, F_0 为第一个特征消融块的输入；

F_2 为经过第二个特征消融块的输出, 第二个特征消融块由两层卷积层级联构成, 第二个特征消融块的第一层卷积核大小为 3×3 , 输入特征维度为 128, 输出特征维度为 64; 第二层卷积核大小为 3×3 , 输入和输出特征维度均为 64, $F_{12}(\cdot)$ 为第二个特征消融块的两层卷积级联操作, F_0, F_1 同时为第二个特征消融块的输入；

F_3 为经过第三个特征消融块的输出, 第三个特征消融块由三层卷积层级联构成, 第三个特征消融块的第一层卷积核大小为 3×3 , 输入特征维度为 192, 输出特征维度为 128; 第二层卷积核大小为 3×3 , 输入特征维度为 128, 输出特征维度为 64; 第三层卷积核大小为 3×3 , 输入和输出特征维度均为 64, $F_{13}(\cdot)$ 为第三个特征消融块的三层卷积级联操作, F_0, F_1, F_2 同时为第三个特征消融块的输入；

F_4 为经过第四个特征消融块的输出, 第四个特征消融块由四层卷积层级联构成, 第四个特征消融块的第一层卷积核大小为 3×3 , 输入特征维度为 256, 输出特征维度为 192; 第二层卷积核大小为 3×3 , 输入特征维度为 192, 输出特征维度为 128; 第三层卷积核大小为 3×3 , 输入特征维度为 128, 输出特征维度为 64; 第四层卷积核大小为 3×3 , 输入和输出特征维度均为 64, $F_{14}(\cdot)$ 为第四个特征消融块的四层卷积级联操作, F_0, F_1, F_2, F_3 同时为第四个特征消融块的输入。

8. 根据权利要求 1 所述的方法, 其特征在于: (4) 中自适应密集连接残差网络的特征融合部分, 由两层卷积层级联构成, 其公式表示如下:

$$H_1 = F_{f1}(F_0, \dots, F_S), (S=2, 3, 4)$$

$$H_2 = F_{f2}(H_1)$$

其中, H_1 为经过特征融合部分的第一层卷积层输出, $F_{f1}(\cdot)$ 为第一层特征融合操作, 特征融合部分第一层的卷积核大小为 1×1 , 输入特征维度为 $64 \times (S+1)$, $S=2, 3, 4$ 分别对应简单图网络分支, 一般图网络分支和复杂图网络分支, 输出特征维度为 64, F_0, \dots, F_S 同时为特征融合部分的第一层卷积输入；

H_2 为经过特征融合部分的第二层卷积层输出, $F_{f2}(\cdot)$ 为第二层特征融合操作, 卷积核大小为 3×3 , 输入和输出特征维度均为 64, H_1 为特征融合部分的第二层卷积输入。

9. 根据权利要求 1 所述的方法, 其特征在于: (4) 中自适应密集连接残差网络的上采样部分, 由四层卷积层和一层亚像素放大层构成, 其公式表示如下:

$$U_1 = F_{u1}(H),$$

$$U_2 = F_{u2}(U_1),$$

$$U_3 = F_{u3}(U_2),$$

$$U=F_U(U_3),$$

$$Y=F_f(U)$$

其中, U_1 为经过上采样部分的第一层卷积层输出, $F_{u1}(\cdot)$ 为第一层上采样操作,卷积核大小为 5×5 ,输入和输出特征维度均为64, H 为上采样部分的第一层卷积输入;

U_2 为经过上采样部分的第二层卷积层输出, $F_{u2}(\cdot)$ 为第二层上采样操作,卷积核大小为 3×3 ,输入特征维度为64,输出特征维度为32, U_1 为上采样部分的第二层卷积输入;

U_3 为经过上采样部分的第三层卷积层输出, $F_{u3}(\cdot)$ 为第三层上采样操作,卷积核大小为 3×3 ,输入特征维度为32,输出特征维度为 $(scale \times scale \times dim)$,其中 $scale=2,3,4$ 分别对应2倍放大因子、3倍放大因子和4倍放大因子, $dim=3$ 为图像维度, U_2 为上采样部分的第三层卷积输入;

U 为亚像素放大后的输出; $F_U(\cdot)$ 为亚像素放大操作,用于将维度从 $(scale \times scale \times dim)$ 降为 dim ,将图像大小从 32×32 放大到 $(32 \times scale) \times (32 \times scale)$,其中 $scale=2,3,4$ 分别对应2倍放大因子、3倍放大因子和4倍放大因子, $dim=3$ 为图像维度, U_3 为亚像素放大层的输入;

Y 为经过上采样部分的第四层卷积层输出, $F_f(\cdot)$ 为第四层卷积操作,卷积核大小为 3×3 ,输入和输出特征维度均为 dim , $dim=3$ 为图像维度, U 为上采样部分的第四层卷积输入。

上述各部分的每层卷积结果均使用Relu函数进行激活。

10.根据权利要求1所述的方法,其特征在于:(4)中在全局进行残差学习,是通过浅层特征部分的第二层卷积层、深层特征部分的卷积层和特征融合部分的卷积层共同拟合如下残差函数:

$$F(F_{-1})=H-F_{-1}=H_2,$$

其中, H 为上采样部分的第一层卷积输入, F_{-1} 为经过浅层特征部分的第一层卷积层输出, $F(F_{-1})$ 为通过浅层特征部分的第二层卷积层、深层特征部分的卷积层和特征融合部分的卷积层对 F_{-1} 进行残差学习操作,其操作结果为特征融合部分的第二层卷积层输出 H_2 。

11.根据权利要求1所述方法,其特征在于:(6)中根据处理后数据的复杂度等级选择对应的网络进行训练,实现如下:

(6a)分别设置初始学习率为0.0001、epoch为50、batch_size为16,epoch为所有训练数据被迭代的次数,自适应密集连接残差网络的优化算法选用指数衰减的梯度下降法,设置衰减步数为10、衰减系数为0.5;

(6b)自适应密集连接残差网络的损失函数选用平均绝对误差函数,公式如下:

$$Loss = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

其中, $n=16$ 为一个batch_size训练样本数, y_i 为真实高分辨图像, \hat{y}_i 为预测的超分辨率图像, $|\cdot|$ 代表取绝对值操作;

(6c)根据处理后数据的复杂度 $C(X)$ 选择被训练的对应网络:

当 $C(X) \in [0,0.4)$ 时,选择自适应密集连接残差网络的简单图网络,执行(6d);

当 $C(X) \in [0.4,0.6)$ 时,选择自适应密集连接残差网络的一般图网络,执行(6e);

当 $C(X) \in [0.6,1]$ 时,选择自适应密集连接残差网络的复杂图网络,执行(6f);

(6d) 对简单图网络参数进行更新：

(6d1) 将16个简单图像输入自适应密集连接残差网络，依次经过浅层特征部分，深层特征部分的简单图网络分支，特征融合部分和上采样部分，得到16个预测超分辨图像；

(6d2) 计算预测超分辨图像和输入简单图像对应的真实高分辨图像之间的平均绝对误差，并用指数衰减的梯度下降法对其进行优化，即采用指数衰减的梯度下降法更新自适应密集连接残差网络的权重和偏置；

(6d3) 重复执行 (6d1) 和 (6d2) 直到所有训练数据被迭代50次时停止；

(6e) 对一般图网络参数进行更新：

(6e1) 将16个一般图像输入自适应密集连接残差网络，依次经过浅层特征部分，深层特征部分的一般图网络分支，特征融合部分和上采样部分，得到16个预测超分辨图像；

(6e2) 计算预测超分辨图像和输入一般图像对应的真实高分辨图像之间的平均绝对误差，并用指数衰减的梯度下降法对其进行优化，即采用指数衰减的梯度下降法更新自适应密集连接残差网络的权重和偏置；

(6e3) 重复执行 (6e1) 和 (6e2) 直到所有训练数据被迭代50次时停止；

(6f) 对复杂图网络参数进行更新：

(6f1) 将16个复杂图像输入自适应密集连接残差网络，依次经过浅层特征部分，深层特征部分的复杂图网络分支，特征融合部分和上采样部分，得到16个预测超分辨图像；

(6f2) 计算预测超分辨图像和输入复杂图像对应的真实高分辨图像之间的平均绝对误差，并用指数衰减的梯度下降法对其进行优化，即采用指数衰减的梯度下降法更新自适应密集连接残差网络的权重和偏置；

(6f3) 重复执行 (6f1) 和 (6f2) 直到所有训练数据被迭代50次时停止。

12. 根据权利要求1所述方法，其特征在于：(8) 中根据待重建图像复杂度 $C(X)$ 自适应选择对应网络进行重构，实现如下：

当 $C(X) < 0.4$ 时，选择简单图网络，将待重建简单图像输入自适应密集连接残差网络，依次经过浅层特征部分，深层特征部分的简单图网络分支，特征融合部分和上采样部分，得到重建后的高分辨图像；

当 $0.4 \leq C(X) < 0.6$ 时，选择一般图网络，将待重建一般图像输入自适应密集连接残差网络，依次经过浅层特征部分，深层特征部分的一般图网络分支，特征融合部分和上采样部分，得到重建后的高分辨图像；

当 $C(X) \geq 0.6$ 时，选择复杂图网络，将待重建复杂图像输入自适应密集连接残差网络，依次经过浅层特征部分，深层特征部分的复杂图网络分支，特征融合部分和上采样部分，得到重建后的高分辨图像。

基于自适应卷积神经网络的图像超分辨率方法

技术领域

[0001] 本发明属于技术图像处理领域,特别图像超分辨率方法,可用于医疗诊断,卫星成像及道路监控。

技术背景

[0002] 近年来,随着社会的发展,图像超分辨率技术在医疗诊断,卫星成像,道路监控等领域起到重要作用。单幅图像超分辨率是一个病态问题,很多科研工作者针对这一病态问题提出了很多算法,主要包括基于插值的算法,基于重建的算法和基于学习的算法。在基于学习的算法中,基于卷积神经网络的深度学习算法取得了明显优于传统算法的优势,成为当前研究的热点。但是当前基于卷积神经网络的算法还存在一些不足:

[0003] 在网络规模方面,该类方法由于网络层数较浅无法充分学习LR图像和HR图像之间的非线性映射关系,后来开始增加网络深度,由此又产生了三个问题:(1) 深层网络模型参数多,网络规模大,在重建过程中花费更多时间;(2) 深层网络模型中浅层特征在后面的层中影响微弱,造成浅层特征信息的丢失;(3) 深层网络在训练过程中难以收敛;在上采样操作所在位置方面,该类方法往往在图像超分辨率之前进行插值预处理,再使用神经网络进行重构,由此产生的问题是:1) 在超分辨率之前进行插值仅仅放大了LR图像的尺寸,并没有带来更多图像信息,并且使计算复杂度更高;2) 在超分辨率之前进行插值操作放大了LR图像的噪声,使结果更模糊;在处理对象方面,该类方法统一处理不同信息量的图像,由此产生的问题是:即使放大一张低信息量的背景图像也会加载深层网络进行处理,造成时间和资源的浪费。

发明内容

[0004] 本发明的目的在于克服现有技术的不足,提出一种基于自适应卷积神经网络的图像超分辨率方法,以使用较少的网络层数降低训练难度,减少插值预处理带来的噪声影响和更高的计算复杂度,并根据图像复杂度自适应处理不同信息量的图像,减小资源浪费。

[0005] 为实现上述目的,本发明的技术方案包括如下步骤:

[0006] (1) 对标准数据集中的高分辨率图像HR进行下采样,得到对应的低分辨率图像LR,形成HR-LR图像对;

[0007] (2) 将HR-LR图像对按指定大小进行分块,对每个LR图像块计算其单位图像大小的信息熵 $h(X)$ 和总变差 $tv(X)$;

[0008] (3) 将复杂度划分成三个等级,依次对应简单图,一般图和复杂图,对LR单位图像大小的信息熵和总变差进行归一化处理,并乘以各自权重,得到LR图像块复杂度 $C(X)$,再根据复杂度所属等级制作相应训练集 $T_i^{scale} = \{t_1^{scale}, t_2^{scale}, \dots, t_j^{scale}, \dots, t_N^{scale}\}$, T_i^{scale} 为第 i 个等级,放大因子为 $scale$ 的训练集, $i=1,2,3, scale=2,3,4, t_j^{scale}$ 为该训练集中第 j 个放大因子为 $scale$ 的HR-LR图像对, $j=1,2,\dots,N, N$ 为该训练集的样本总数;

[0009] (4) 构建依次由浅层特征提取、深层特征提取、特征融合和上采样四部分级联,并

在全局进行残差学习的自适应密集连接残差网络,其中,深层特征提取部分根据输入图像复杂度的不同包含不同数量的特征消融块,形成不同网络分支;

[0010] (5) 以设定的概率确定选择哪种等级的训练集T,从所选数据集T中随机获取batch_size个训练数据,并对这些数据随机做水平、垂直翻转和90度旋转操作处理,其中选择简单图像训练集的概率为0.1,选择一般图像训练集的概率为0.3,选择复杂图像训练集的概率为0.6;

[0011] (6) 将(5)处理后的数据输入到(4)构建的自适应密集连接残差网络中,并根据处理后数据的复杂度等级选择对应的网络进行训练,得到训练好的自适应密集连接残差网络;

[0012] (7) 按(2)和(3)对待重建图像按指定大小分块,计算每个块的复杂度 $C_i(X)$, $i=1, 2, \dots, M$, M为待重建图像所分成的总块数,计算所有块复杂度的平均值,并加上设定的阈值0.25,得到待重建图像的复杂度 $C(X)$;

[0013] (8) 将待重建图像输入到训练好的自适应密集连接残差网络,根据待重建图像复杂度 $C(X)$ 自适应选择对应的网络进行重构,得到超分辨后的图像。

[0014] 本发明有益效果为:

[0015] 第一,本发明由于在自适应密集连接残差网络的深层特征部分构建了特征消融块结构,可以充分挖掘接收的特征信息,使得网络使用较少的层数便可充分学习LR图像和HR图像之间的非线性映射关系;

[0016] 第二,本发明由于在自适应密集连接残差网络中使用了特征融合结构,对浅层特征和深层特征部分的输出结果进行融合,有效的利用了网络各层信息,提高了重建图像的效果;

[0017] 第三,本发明由于在自适应密集连接残差网络中采用了密集连接方式和残差学习策略,避免了浅层特征丢失,降低了网络训练难度;

[0018] 第四,本发明由于在自适应密集连接残差网络最后采用上采样部分对低分辨率图像进行放大,避免了插值预处理带来更高的计算复杂度和噪声影响,进一步提高了重建质量;

[0019] 第五,本发明根据输入图像复杂度的不同自适应选择不同规模网络进行重构,并且在不同规模网络间采用参数共享,有效节省了计算资源。

附图说明

[0020] 图1为本发明的实现流程图;

[0021] 图2为本发明中构建的自适应密集连接残差网络ADCRN结构图;

[0022] 图3为本发明中待处理的低分辨率图像;

[0023] 图4为分别使用现有双三次插值和本发明对图3进行四倍超分辨后的结果对比图;

[0024] 图5为分别使用现有基于卷积神经网络的超分辨方法和本发明对Set5测试集进行四倍超分辨的性能和参数数量对比图。

具体实施方式

[0025] 参阅图1,本发明的具体实施步骤如下:

[0026] 步骤1.对标准数据集中的高分辨率图像HR进行下采样,得到对应的低分辨率图像

LR,形成HR-LR图像对。

[0027] 所述标准数据集,是DIV2K的训练集,其中包含了800张高分辨率图像;

[0028] 所述下采样,是采用双三次插值函数,对每张高分辨率图像HR分别按 $\frac{1}{2}, \frac{1}{3}, \frac{1}{4}$ 插值因子作双三次插值,得到对应的2倍缩小LR图像、3倍缩小LR图像和4倍缩小LR图像,分别形成了2倍、3倍和4倍HR-LR图像对。

[0029] 步骤2.将HR-LR图像对按指定大小进行分块,并对每个LR图像块计算其单位图像大小的信息熵 $h(X)$ 和总变差 $tv(X)$ 。

[0030] 2.1)对每个HR-LR图像对进行如下处理:

[0031] 首先,对HR-LR图像对中的HR图像,在横坐标上按照 $32 \times scale$ 的大小、 $24 \times scale$ 的移动步长进行分割,得到分割后的横坐标 x^h ,在纵坐标按照 $32 \times scale$ 的大小、 $24 \times scale$ 的移动步长进行分割,得到分割后的纵坐标 y^h ;

[0032] 然后,对 x^h, y^h 分别乘以 $\frac{1}{scale}$,得到缩小后的坐标 (x^l, y^l) ,其中 $scale=2, 3, 4$ 分别对应2倍放大因子,3倍放大因子和4倍放大因子;

[0033] 最后,在HR-LR图像对中的HR图像上按照分割后的坐标 (x^h, y^h) 进行分割,得到HR图像块,在HR-LR图像对中的LR图像上按照缩小后的坐标 (x^l, y^l) 进行分割得到LR图像块;

[0034] 2.2)对每个LR图像块,将RGB通道的LR图像块转换为YCbCr通道的LR图像块,得到Y通道图像,其中转换公式如下:

[0035] $Y = 0.299 \times R + 0.587 \times G + 0.114 \times B$,

[0036] 其中R代表红色通道,G代表绿色通道,B代表蓝色通道,Y代表明亮度;

[0037] 2.3)计算Y通道图像的信息熵 $H(X)$:

[0038] $H(X) = -\sum p(i) \log(p(i)), i = 0, 1, \dots, 255$,

[0039] 其中, $p(i)$ 表示图像块中灰度值 i 出现的概率;

[0040] 2.4)根据信息熵 $H(X)$ 计算Y通道图像单位图像信息熵 $h(X)$:

[0041] $h(X) = \frac{H(X)}{32^2}$;

[0042] 2.5)计算Y通道图像的总变差 $TV(X)$:

[0043] $TV(X) = \sum_{i,j} ((x_{i,j+1} - x_{i,j})^2 + (x_{i+1,j} - x_{i,j})^2)^{\frac{1}{2}}$,

[0044] 其中 $x_{i,j}$ 为 (i, j) 位置处的灰度值, $x_{i,j+1}$ 为 $(i, j+1)$ 位置处的灰度值, $x_{i+1,j}$ 为 $(i+1, j)$ 处的灰度值;

[0045] 2.6)根据总变差 $TV(X)$ 计算Y通道图像单位图像总变差 $tv(X)$:

[0046] $tv(X) = \frac{TV(X)}{32^2}$ 。

[0047] 步骤3.对LR单位图像大小的信息熵和总变差进行归一化处理,并根据各自权重,得到LR图像块的复杂度 $C(X)$ 。

[0048] 3.1)从步骤2计算的LR单位图像大小的信息熵 $h(X)$ 和总变差 $tv(X)$ 中找到最大值和最小值,即找到单位图像大小的信息熵 $h(X)$ 的最大值为 $h_{\max}(X)$ 、最小值为 $h_{\min}(X)$,单位图

像大小的总变差 $tv(X)$ 的最大值为 $tv_{\max}(X)$ 、最小值为 $tv_{\min}(X)$ ；

[0049] 3.2) 分别设置归一化后信息熵和总变差的权重均为0.5；

[0050] 3.3) 根据(3.1)找出的 $h_{\max}(X)$, $h_{\min}(X)$, $tv_{\max}(X)$, $tv_{\min}(X)$ 和(3.2)设置的权重计算LR图像块复杂度 $C(X)$ ：

$$[0051] \quad C(X) = 0.5 \times \frac{tv(X) - tv_{\min}(X)}{tv_{\max}(X) - tv_{\min}(X)} + 0.5 \times \frac{h(X) - h_{\min}(X)}{h_{\max}(X) - h_{\min}(X)},$$

[0052] 其中, $h(X)$, $tv(X)$ 分别为当前LR单位图像信息熵和总变差,且 $C(X) \in [0, 1]$ 。

[0053] 步骤4.对复杂度 $C(X)$ 进行等级划分。

[0054] 本步骤是根据复杂度 $C(X)$ 的取值范围,将其划分成三个等级,即：

[0055] 将 $0 \leq C(X) < 0.4$ 的图像划分为简单图；

[0056] 将 $0.4 \leq C(X) < 0.6$ 的图像划分为一般图；

[0057] 将 $0.6 \leq C(X)$ 的图像划分为复杂图。

[0058] 步骤5.在每个放大因子 $scale$ 下,制作相应训练集 T 。

[0059] 本步骤是根据复杂度所属等级制作相应训练集 $T_i^{scale} = \{t_1^{scale}, t_2^{scale}, \dots, t_j^{scale}, \dots, t_N^{scale}\}$, T_i^{scale}

为第 i 个等级,放大因子为 $scale$ 的训练集, $i=1, 2, 3$, $scale=2, 3, 4$, t_j^{scale} 为该训练集中第 j 个放大因子为 $scale$ 的HR-LR图像对, $j=1, 2, \dots, N$, N 为该训练集的样本总数,具体过程为：

[0060] 对于2倍HR-LR图像对,根据其中LR图像块的复杂度 $C(X)$ 制作相应训练集 T^2 ：

[0061] 当 $0 \leq C(X) < 0.4$ 时,将该LR图像块和对应的HR图像块写入第一个h5文件,记作 T_1^2 ；

[0062] 当 $0.4 \leq C(X) < 0.6$ 时,将该LR图像块和对应的HR图像块写入第二个h5文件,记作 T_2^2 ；

[0063] 当 $0.6 \leq C(X)$ 时,将该LR图像块和对应的HR图像块写入第三个h5文件,记作 T_3^2 ；

[0064] 对于3倍HR-LR图像对,根据其中LR图像块的复杂度 $C(X)$ 制作相应训练集 T^3 ：

[0065] 当 $0 \leq C(X) < 0.4$ 时,将该LR图像块和对应的HR图像块写入第四个h5文件,记作 T_1^3 ；

[0066] 当 $0.4 \leq C(X) < 0.6$ 时,将该LR图像块和对应的HR图像块写入第五个h5文件,记作 T_2^3 ；

[0067] 当 $0.6 \leq C(X)$ 时,将该LR图像块和对应的HR图像块写入第六个h5文件,记作 T_3^3 ；

[0068] 对于4倍HR-LR图像对,根据其中LR图像块的复杂度 $C(X)$ 制作相应训练集 T^4 ：

[0069] 当 $0 \leq C(X) < 0.4$ 时,将该LR图像块和对应的HR图像块写入第七个h5文件,记作 T_1^4 ；

[0070] 当 $0.4 \leq C(X) < 0.6$ 时,将该LR图像块和对应的HR图像块写入第八个h5文件,记作 T_2^4 ；

[0071] 当 $0.6 \leq C(X)$ 时,将该LR图像块和对应的HR图像块写入第九个h5文件,记作 T_3^4 。

[0072] 步骤6.构建自适应密集连接残差网。

[0073] 参照图2,本步骤构建的自适应密集连接残差网络包括浅层特征部分SF、深层特征部分DF、特征融合部分FF和上采样部分UP,各部分的结构如下：

[0074] 6.1) 浅层特征部分SF,由两层卷积层级联构成,其公式表示如下：

[0075] $F_{-1}=F_{s_1}(x)$,

[0076] $F_0=F_{s_2}(F_{-1})$

[0077] 其中, F_{-1} 为经过浅层特征部分的第一层卷积层输出, $F_{s_1}(\cdot)$ 为第一层浅层特征提取操作,卷积核大小为 3×3 ,输入图像维度为 $\text{dim}=3$,输出特征维度为64, x 为输入图像;

[0078] F_0 为经过浅层特征部分的第二层卷积层输出, $F_{s_2}(\cdot)$ 为第二层浅层特征提取操作,卷积核大小为 3×3 ,输入和输出特征维度均为64, F_{-1} 为浅层特征部分的第二层卷积输入。

[0079] 6.2) 深层特征部分DF,由简单图网络分支S、一般图网络分支G和复杂图网络分支C并联构成,每一网络分支又由不同数量的特征消融块密集连接组成,其中:

[0080] 简单图网络分支包含2个特征消融块,一般图网络分支包含3个特征消融块,复杂图网络分支包含4个特征消融块,并且三种网络分支之间的参数共享,即一般图网络分支的3个特征消融块中前2个特征消融块与简单图网络分支中2个特征消融块相同,复杂图网络分支的4个特征消融块中前3个特征消融块与一般图网络分支中的3个特征消融块相同;

[0081] 每个特征消融块的表达式如下:

[0082] $F_1=F_{11}(F_0)$,

[0083] $F_2=F_{12}(F_0,F_1)$,

[0084] $F_3=F_{13}(F_0,F_1,F_2)$,

[0085] $F_4=F_{14}(F_0,F_1,F_2,F_3)$

[0086] 其中, F_1 为经过第一个特征消融块FAB1的输出,第一个特征消融块包含一层卷积层,卷积核大小为 3×3 ,输入和输出特征维度为64, $F_{11}(\cdot)$ 为第一个特征消融块操作, F_0 为第一个特征消融块的输入;

[0087] F_2 为经过第二个特征消融块FAB2的输出,第二个特征消融块由两层卷积层级联构成,第二个特征消融块的第一层卷积核大小为 3×3 ,输入特征维度为128,输出特征维度为64;第二层卷积核大小为 3×3 ,输入和输出特征维度均为64, $F_{12}(\cdot)$ 为第二个特征消融块的两层卷积级联操作, F_0,F_1 同时为第二个特征消融块的输入;

[0088] F_3 为经过第三个特征消融块FAB3的输出,第三个特征消融块由三层卷积层级联构成,第三个特征消融块的第一层卷积核大小为 3×3 ,输入特征维度为192,输出特征维度为128;第二层卷积核大小为 3×3 ,输入特征维度为128,输出特征维度为64;第三层卷积核大小为 3×3 ,输入和输出特征维度均为64, $F_{13}(\cdot)$ 为第三个特征消融块的三层卷积级联操作, F_0,F_1,F_2 同时为第三个特征消融块的输入;

[0089] F_4 为经过第四个特征消融块FAB4的输出,第四个特征消融块由四层卷积层级联构成,第四个特征消融块的第一层卷积核大小为 3×3 ,输入特征维度为256,输出特征维度为192;第二层卷积核大小为 3×3 ,输入特征维度为192,输出特征维度为128;第三层卷积核大小为 3×3 ,输入特征维度为128,输出特征维度为64;第四层卷积核大小为 3×3 ,输入和输出特征维度均为64, $F_{14}(\cdot)$ 为第四个特征消融块的四层卷积级联操作, F_0,F_1,F_2,F_3 同时为第四个特征消融块的输入。

[0090] 6.3) 自适应密集连接残差网络的特征融合部分FF,由两层卷积层级联构成,其公式表示如下:

[0091] $H_1=F_{f1}(F_0,\cdots F_S)$, ($S=2,3,4$)

[0092] $H_2 = F_{f2}(H_1)$

[0093] 其中, H_1 为经过特征融合部分的第一层卷积层输出, $F_{f1}(\cdot)$ 为第一层特征融合操作, 特征融合部分第一层的卷积核大小为 1×1 , 输入特征维度为 $64 \times (S+1)$, $S=2, 3, 4$ 分别对应简单图网络分支, 一般图网络分支和复杂图网络分支, 输出特征维度为 64, F_0, \dots, F_S 同时为特征融合部分的第一层卷积输入;

[0094] H_2 为经过特征融合部分的第二层卷积层输出, $F_{f2}(\cdot)$ 为第二层特征融合操作, 卷积核大小为 3×3 , 输入和输出特征维度均为 64, 为特征融合部分的第二层卷积输入。

[0095] 6.4) 上采样部分 UP, 其由四层卷积层和一层亚像素放大层构成, 其公式表示如下:

[0096] $U_1 = F_{u1}(H)$,

[0097] $U_2 = F_{u2}(U_1)$,

[0098] $U_3 = F_{u3}(U_2)$,

[0099] $U = F_U(U_3)$,

[0100] $Y = F_f(U)$

[0101] 其中, U_1 为经过上采样部分的第一层卷积层输出, $F_{u1}(\cdot)$ 为第一层上采样操作, 卷积核大小为 5×5 , 输入和输出特征维度均为 64, H 为上采样部分的第一层卷积输入;

[0102] U_2 为经过上采样部分的第二层卷积层输出, $F_{u2}(\cdot)$ 为第二层上采样操作, 卷积核大小为 3×3 , 输入特征维度为 64, 输出特征维度为 32, U_1 为上采样部分的第二层卷积输入;

[0103] U_3 为经过上采样部分的第三层卷积层输出, $F_{u3}(\cdot)$ 为第三层上采样操作, 卷积核大小为 3×3 , 输入特征维度为 32, 输出特征维度为 $(scale \times scale \times dim)$, 其中 $scale=2, 3, 4$ 分别对应 2 倍放大因子、3 倍放大因子和 4 倍放大因子, $dim=3$ 为图像维度, U_2 为上采样部分的第三层卷积输入;

[0104] U 为亚像素放大后的输出; $F_U(\cdot)$ 为亚像素放大操作, 用于将维度从 $(scale \times scale \times dim)$ 降为 dim , 将图像大小从 32×32 放大到 $(32 \times scale) \times (32 \times scale)$, 其中 $scale=2, 3, 4$ 分别对应 2 倍放大因子、3 倍放大因子和 4 倍放大因子, $dim=3$ 为图像维度, U_3 为亚像素放大层的输入;

[0105] Y 为经过上采样部分的第四层卷积层输出, $F_f(\cdot)$ 为第四层卷积操作, 卷积核大小为 3×3 , 输入和输出特征维度均为 dim , $dim=3$ 为图像维度, U 为上采样部分的第四层卷积输入。

[0106] 上述各部分的每层卷积结果均使用 Relu 函数进行激活。

[0107] 步骤 7. 自适应密集连接残差网络在全局进行残差学习。

[0108] 自适应密集连接残差网络在全局进行残差学习, 是通过浅层特征部分的第二层卷积层、深层特征部分的卷积层和特征融合部分的卷积层共同拟合如下残差函数:

[0109] $F(F_{-1}) = H - F_{-1} = H_2$,

[0110] 其中, H 为上采样部分的第一层卷积输入, F_{-1} 为经过浅层特征部分的第一层卷积层输出, $F(F_{-1})$ 为通过浅层特征部分的第二层卷积层、深层特征部分的卷积层和特征融合部分的卷积层对 F_{-1} 进行残差学习操作, 其操作结果为特征融合部分的第二层卷积层输出 H_2 。

[0111] 步骤 8. 在每个放大因子 $scale$ 下, 获取自适应密集连接残差网络的输入数据。

[0112] 8.1) 在每个放大因子 $scale$ 下, 选择自适应密集连接残差网络相应训练集:

[0113] 对于 2 倍 HR-LR 图像对, 分别以概率 0.1 选择简单图训练集 T_1^2 , 以概率 0.3 选择一般

图训练集 T_2^2 ，以概率0.6选择复杂图训练集 T_3^2 ；

[0114] 对于3倍HR-LR图像对，分别以概率0.1选择简单图训练集 T_1^3 ，以概率0.3选择一般图训练集 T_2^3 ，以概率0.6选择复杂图训练集 T_3^3 ；

[0115] 对于4倍HR-LR图像对，分别以概率0.1选择简单图训练集 T_1^4 ，以概率0.3选择一般图训练集 T_2^4 ，以概率0.6选择复杂图训练集 T_3^4 ；

[0116] 8.2) 在相应训练集中获取自适应密集连接残差网络的输入数据：

[0117] 8.2a) 从所选训练集中随机获取batch_size个训练数据，即先生成batch_size大小的一维向量 $R^{1 \times \text{batch_size}}$ ， $R^{1 \times \text{batch_size}}$ 中每个元素为[1,N]区间中一个整数，N为所选训练集的样本总数，且 $R^{1 \times \text{batch_size}}$ 中所有元素值不同；然后，按照 $R^{1 \times \text{batch_size}}$ 中的值在训练集T中获取对应的训练数据，总共获取batch_size=16个训练数据；

[0118] 8.2b) 对获取的16个训练数据随机做水平、垂直翻转和90度旋转操作处理，即在[0,1)区间随机产生两个随机数n,m,根据n,m的取值进行不同操作：

[0119] 当 $n < 0.3$ 时，对获取的数据做水平翻转；

[0120] 当 $0.3 \leq n \leq 0.7$ 时，对获取的数据不做变化；

[0121] 当 $n > 0.7$ 时，对获取的数据做垂直翻转；

[0122] 当 $m < 0.5$ 时，对获取的数据做90度旋转操作；

[0123] 当 $m > 0.5$ 时对获取的数据不做变化。

[0124] 步骤9. 对自适应密集连接残差网络进行训练。

[0125] 本步骤是根据处理后数据的复杂度等级选择对应的网络进行训练，实现如下：

[0126] (9.1) 分别设置初始学习率为0.0001、epoch为50、batch_size为16，epoch为所有训练数据被迭代的次数，自适应密集连接残差网络的优化算法选用指数衰减的梯度下降法，设置衰减步数为10、衰减系数为0.5；

[0127] (9.2) 自适应密集连接残差网络的损失函数选用平均绝对误差函数，公式如下：

$$[0128] \quad Loss = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

[0129] 其中，n=16为一个batch_size训练样本数， y_i 为真实高分辨图像， \hat{y}_i 为预测的超分辨率图像， $|\cdot|$ 代表取绝对值操作；

[0130] (9.3) 根据处理后数据的复杂度C(X)选择被训练的对应网络：

[0131] 当 $C(X) \in [0, 0.4)$ 时，选择自适应密集连接残差网络的简单图网络，执行(12.4)；

[0132] 当 $C(X) \in [0.4, 0.6)$ 时，选择自适应密集连接残差网络的一般图网络，执行(12.5)；

[0133] 当 $C(X) \in [0.6, 1]$ 时，选择自适应密集连接残差网络的复杂图网络，执行(12.6)；

[0134] (9.4) 对简单图网络参数进行更新：

[0135] (9.4a) 将16个简单图像输入自适应密集连接残差网络，依次经过浅层特征部分，深层特征部分的简单图网络分支，特征融合部分和上采样部分，得到16个预测超分辨率图像；

[0136] (9.4b) 计算预测超分辨率图像和输入简单图像对应的真实高分辨图像之间的平均绝对误差，并用指数衰减的梯度下降法对其进行优化，即采用指数衰减的梯度下降法更新

自适应密集连接残差网络的权重和偏置；

[0137] (9.4c) 重复执行 (9.4a) 和 (9.4b)，直到所有训练数据被迭代50次时停止；

[0138] (9.5) 对一般图网络参数进行更新；

[0139] (9.5a) 将16个一般图像输入自适应密集连接残差网络，依次经过浅层特征部分、深层特征部分的一般图网络分支、特征融合部分和上采样部分，得到16个预测超分辨率图像；

[0140] (9.5b) 计算预测超分辨率图像和输入一般图像对应的真实高分辨图像之间的平均绝对误差，并用指数衰减的梯度下降法对其进行优化，即采用指数衰减的梯度下降法更新自适应密集连接残差网络的权重和偏置；

[0141] (9.5c) 重复执行 (9.5a) 和 (9.5b)，直到所有训练数据被迭代50次时停止；

[0142] (9.6) 对复杂图网络参数进行更新；

[0143] (9.6a) 将16个复杂图像输入到自适应密集连接残差网络，依次经过浅层特征部分，深层特征部分的复杂图网络分支、特征融合部分和上采样部分，得到16个预测超分辨率图像；

[0144] (9.6b) 计算预测超分辨率图像和输入复杂图像对应的真实高分辨图像之间的平均绝对误差，并用指数衰减的梯度下降法对其进行优化，即采用指数衰减的梯度下降法更新自适应密集连接残差网络的权重和偏置；

[0145] (9.6c) 重复执行 (9.6a) 和 (9.6b)，直到所有训练数据被迭代50次时停止。

[0146] 步骤10. 计算待重建图像的复杂度C(X)。

[0147] 10.1) 将RGB通道的待重建图像转换为YCbCr通道的待重建图像，得到Y通道图像，其中，转换公式如下：

[0148] $Y = 0.299 \times R + 0.587 \times G + 0.114 \times B$ ，

[0149] R代表红色通道，G代表绿色通道，B代表蓝色通道，Y代表明亮度；

[0150] 10.2) 对Y通道图像进行分块，在横坐标上按照大小和移动步长均为32得到分割后的横坐标 x^{test} ，在纵坐标按照大小和移动步长均为32进行分割，得到分割后的纵坐标 y^{test} ，并根据分割后的坐标 $(x^{\text{test}}, y^{\text{test}})$ 对Y通道图像进行分块，得到一系列图像块 $Q = \{X_1, \dots, X_m, \dots, X_M\}$ ，其中 X_m 为第m个Y通道图像块， $m = 1, 2, \dots, M$ ，M为分割Y通道图像的总块数；

[0151] 10.3) 计算第m个Y通道图像块的复杂度 $C(X_m)$ ：

[0152] 10.3a) 计算第m个Y通道图像块的信息熵 $H(X_m)$ ：

[0153] $H(X_m) = -\sum p(i) \log(p(i))$ ， $i = 0, 1, \dots, 255$ ，

[0154] 其中， $p(i)$ 表示第m个Y通道图像块中灰度值i出现的概率；

[0155] 10.3b) 根据信息熵 $H(X_m)$ 计算单位图像信息熵 $h(X_m)$ ：

[0156] $h(X_m) = \frac{H(X_m)}{32^2}$ ；

[0157] 10.3c) 计算第m个Y通道图像块的总变差 $TV(X_m)$ ：

[0158] $TV(X_m) = \sum_{i,j} ((x_{i,j+1} - x_{i,j})^2 + (x_{i+1,j} - x_{i,j})^2)^{\frac{1}{2}}$ ，

[0159] 其中 $x_{i,j}$ 为第m个Y通道图像块中 (i, j) 位置处的灰度值， $x_{i,j+1}$ 为 $(i, j+1)$ 位置处的灰度值， $x_{i+1,j}$ 为 $(i+1, j)$ 处的灰度值；

[0160] 10.3d) 根据总变差 $TV(X_m)$ 计算单位图像总变差 $tv(X_m)$ ：

$$[0161] \quad tv(X_m) = \frac{TV(X_m)}{32^2},$$

[0162] 10.3e) 根据训练数据中的最小、最大单位图像信息熵和总变差和设置的权重, 计算第m个Y通道图像块的复杂度C(X_m):

$$[0163] \quad C(X_m) = 0.5 \times \frac{tv(X_m) - tv_{\min}(X)}{tv_{\max}(X) - tv_{\min}(X)} + 0.5 \times \frac{h(X_m) - h_{\min}(X)}{h_{\max}(X) - h_{\min}(X)},$$

[0164] 其中, h(X_m), tv(X_m) 分别为第m个Y通道图像块单位图像信息熵和总变差, h_{max}(X)、h_{min}(X) 为训练数据中最大和最小单位图像信息熵, tv_{max}(X)、tv_{min}(X) 为训练数据中最大和最小单位图像总变差;

[0165] 10.4) 根据设定阈值0.25计算待重建图像平均复杂度C(X):

$$[0166] \quad C(X) = \frac{\sum_m C(X_m)}{M} + 0.25, \quad (m=1, 2, \dots, M);$$

[0167] 其中, C(X) 为Y通道图像的复杂度, 即待重建图像的复杂度, C(X_m) 为第m个Y通道图像块的复杂度, M为分割Y通道图像的总块数。

[0168] 步骤11. 将待重建图像输入到自适应密集连接残差网络, 得到超分辨后的图像。

[0169] 本步骤是根据待重建图像复杂度C(X) 自适应选择对应的网络进行重构, 得到超分辨后的图像:

[0170] 当C(X) < 0.4时, 选择简单图网络, 将待重建简单图像输入自适应密集连接残差网络, 依次经过浅层特征部分, 深层特征部分的简单图网络分支, 特征融合部分和上采样部分, 得到重建后的高分辨图像;

[0171] 当0.4 ≤ C(X) < 0.6时, 选择一般图网络, 将待重建一般图像输入到自适应密集连接残差网络, 依次经过浅层特征部分, 深层特征部分的一般图网络分支, 特征融合部分和上采样部分, 得到重建后的高分辨图像;

[0172] 当C(X) ≥ 0.6时, 选择复杂图网络, 将待重建复杂图像输入自适应密集连接残差网络, 依次经过浅层特征部分, 深层特征部分的复杂图网络分支, 特征融合部分和上采样部分, 得到重建后的高分辨图像。

[0173] 本发明的效果可以通过以下仿真实验进一步说明:

[0174] 为了具体说明本发明的优势和特点, 下面对本发明和现有技术进行仿真, 分析其超分辨效果。

[0175] 一. 实验条件

[0176] 本实验的软件平台为: Ubuntu系统; 硬件平台为: GTX 1080ti GPU; 开发环境为 tensorflow, 测试图像选用如图3所示的 (64, 64, 3) 大小的butterfly图像, 测试集选用Set5测试集。

[0177] 二. 实验内容

[0178] 实验1. 用现有双三次插值方法和本发明方法分别对单个测试图像进行四倍超分辨, 结果如图4所示, 其中, 图4(a) 是用现有双三次插值进行四倍超分辨的结果, 图4(b) 是用本发明方法进行四倍超分辨的结果。

[0179] 实验2. 用本发明方法对Set5测试集进行四倍超分辨, 计算重构图像的峰值信噪

比,再与现有基于卷积神经网络方法进行峰值信噪比和参数量对比,结果如图5所示。

[0180] 从图5可见,本发明方法ADCRN对Set5测试集进行四倍超分辨的峰值信噪比为31.85,现有基于卷积神经网络方法SRCNN、DRRN、VDSR、DRCN和RED30对Set5测试集进行四倍超分辨的峰值信噪比分别为30.48、31.68、31.35、31.53和31.51;本发明方法ADCRN的参数量为1512K,现有基于卷积神经网络方法SRCNN、DRRN、VDSR、DRCN和RED30的参数量分别为8K、297K、665K、1774K和4131K,表明本发明使用较少的参数,能达到明显优于其他现有方法的重构效果。

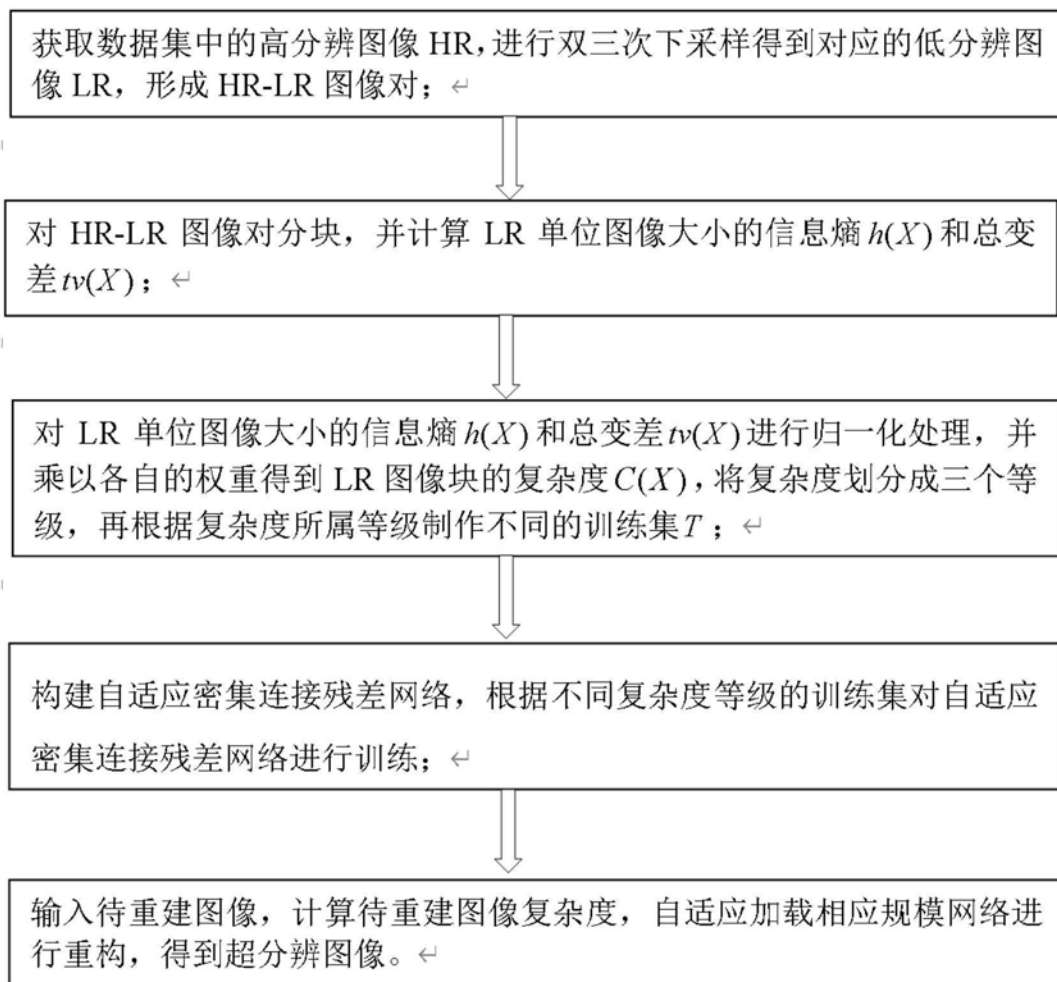


图1




图2



图3



(a)



(b)

图4




图5